

INFORME TÉCNICO

Etapa 1 · Construcción de la Base de Conocimiento

Diseño, implementación y conformidad de la entrega

Encoder	BAAI/bge-m3
Índice	FAISS IndexFlatIP · similitud coseno
Corpus indexado	202.350 fragmentos · 1.734 documentos
Salida	50 consultas · top-3 documentos · top-10 fragmentos
Fecha de verificación	13 de agosto de 2026

Resumen ejecutivo

La solución implementa un pipeline multiformato y multilingüe que extrae, limpia y fragmenta el corpus; codifica los fragmentos con BAAI/bge-m3; persiste un índice FAISS; y produce los rankings requeridos para q001–q050. La recuperación usa únicamente un encoder, vectores normalizados y metadata. No interviene ningún modelo generativo.

La revisión final abrió el binario real, recorrió la metadata completa y comprobó alineación, dimensión y normas. También contrastó cada fragmento reportado con su chunk de origen y saneó el texto de salida para terminar siempre en una frontera oracional completa.

1. Preprocesamiento de las fuentes

Cada archivo provisto por la organización se trata como un documento y recibe un doc_id determinístico derivado de su ruta relativa. La extracción conserva el contenido útil y separa la metadata descriptiva.

Formato	Extracción y representación
PDF	Extracción por página con pdfplumber; orden de lectura y remoción de encabezados/pies repetidos.
HTML	BeautifulSoup elimina script, style y noscript y conserva texto visible.
JSON	Selección de título/cuerpo; fallback sobre valores textuales; URL y autores se tratan como metadata.
CSV / XLSX	Cada fila se representa como pares columna: valor.
Imágenes	OCR con Tesseract cuando existe texto relevante.
PBF	Decodificación por capa y atributos; deduplicación por nivel de zoom.
TXT / Markdown	Lectura directa y uso de párrafos, encabezados y separadores.

Limpieza y trazabilidad

- Normalización Unicode/UTF-8, caracteres de control, espacios y saltos de línea.
- Detección del idioma predominante y marcado en metadata.
- Eliminación de boilerplate repetitivo sin valor informativo.
- Conservación de fuente, formato, fenómeno, idioma, posición y offsets.

Cobertura

La corrida documentada procesó 1.754 de 1.835 recursos (95,6 %). Los 81 restantes quedaron diagnosticados como manifiestos o catálogos, PDFs escaneados sin OCR, archivos corruptos, imágenes sin texto o contenido genuinamente corto. La base final contiene 1.734 documentos con fragmentos indexables.

2. Estrategia de chunking y justificación

Se utiliza una estrategia híbrida estructural-oracional. Primero se respetan bloques y párrafos; después se agrupan oraciones completas hasta el presupuesto configurado. Cuando un bloque no cabe, el corte retrocede a la última frontera oracional válida.

Parámetro	Valor	Justificación
Máximo de tokens	450	Margen frente al límite efectivo de 512 del encoder.
Máximo de palabras	250	Cumple directamente el límite del formato de salida.
Solapamiento	1 oración	Reduce pérdida de contexto entre fronteras.
Prosa sobredimensionada	fail / skip-document	Nunca se divide internamente una oración real.

Complejidad lingüística

El divisor multilingüe distingue cierres de oración de abreviaturas, iniciales, elipsis y puntos decimales. Los fallbacks por pares, espacios o caracteres quedan restringidos a CSV, XLSX y PBF, cuyas representaciones clave-valor no constituyen prosa. Para PDF, HTML, JSON y texto, una oración sobredimensionada se rechaza o se omite con trazabilidad.

Salvaguarda de salida

Como control independiente, el generador retira continuaciones parciales al inicio y conserva hasta la última puntuación oracional completa, sin superar 250 palabras. La Sección 9.2.1 permite esta subdivisión manteniendo el chunk_id original. En la revisión final se sanearon 500 textos y el chequeo posterior confirmó fronteras y cardinalidades intactas.

Metadata por fragmento

Cada registro conserva los ocho campos obligatorios: doc_id, chunk_id, fuente, formato, fenomeno, posicion, num_tokens y texto. También incluye idioma, num_palabras y offsets cuando están disponibles. Los 202.350 chunk_id son únicos.

3. Encoder y codificación semántica

Criterio	Decisión
Modelo	BAAI/bge-m3, encoder denso público y no generativo.
Idiomas	Más de 100 idiomas; cubre español, inglés y portugués.
Dimensión	1.024 valores por vector.
Longitud efectiva	512 tokens por eficiencia; chunks limitados a 450.
Prefijos	Consulta y pasaje sin prefijo, persistido en manifest.json.
Selección	Equilibrio entre recuperación multilingüe, contexto y reproducibilidad.

Se emplea un solo encoder; por ello no aplica fusión CombSUM, CombMNZ o RRF. Las consultas se codifican con el mismo modelo, longitud y prefijo registrados en el manifiesto. Las URL se excluyen del texto visto por el encoder cuando corresponde, mientras el texto trazable permanece en metadata.

4. Índice FAISS

Se seleccionó IndexFlatIP. Los embeddings y las consultas se normalizan a norma unitaria; así, el producto interno equivale a similitud coseno. La búsqueda es exhaustiva, exacta y determinística.

- Persistencia estándar mediante `faiss.write_index` y carga con `faiss.read_index`.
- La línea `i` de `metadata.jsonl` corresponde al vector interno `i` de FAISS.
- Carga rechazada si `index.ntotal` y el número de líneas difieren.
- Escrituras atómicas para reducir el riesgo de artefactos parciales.

La inspección real confirmó IndexFlatIP, dimensión 1.024, 202.350 vectores y 202.350 registros. Una muestra uniforme de 1.000 vectores presentó norma unitaria dentro de tolerancia $1e-3$.

5. Módulo de recuperación

Paso	Operación
1	Leer modelo, dimensión, longitud y prefijo desde manifest.json.
2	Codificar y normalizar la consulta en el mismo espacio vectorial.
3	Buscar top-k global mediante producto interno en IndexFlatIP.
4	Resolver cada id interno contra la línea correspondiente de metadata.
5	Sumar scores por doc_id y seleccionar los 3 documentos principales.
6	Conservar por separado el ranking global y elegir 10 fragmentos válidos.
7	Ampliar k de forma adaptativa si faltan documentos o fragmentos.

Formato de salida

Cada línea contiene query_id; documents con exactamente tres objetos {rank, doc_id}; y fragments con exactamente diez objetos {rank, chunk_id, doc_id, text}. Las 50 líneas mantienen el orden q001-q050. El ranking de fragmentos no se restringe artificialmente a los tres documentos agregados.

Agregación documental

Para cada consulta se recuperan inicialmente 60 vecinos. El score de documento es la suma de las similitudes de sus chunks presentes en ese conjunto. Los documentos se ordenan por score descendente y doc_id como desempate determinístico.

Restricciones

- No se usa decoder, LLM, síntesis generativa, reranking generativo ni expansión generativa.
- No se implementó grafo de conocimiento; es un componente bonus.
- El generador de entrega es autónomo respecto de src/codefest_ad_astra y escribe atómicamente.

6. Evidencia de conformidad

Comprobación	Resultado
Tipo / dimensión	IndexFlatIP / 1.024
Vectores / metadata	202.350 / 202.350, alineados
Documentos / fuentes	1.734 / 1.734
Fenómeno 1	134.224 fragmentos
Fenómeno 2	36.644 fragmentos
Fenómeno 3	31.482 fragmentos
Tokens	347,5 promedio; 450 máximo
Consultas	50, en orden q001-q050
Salida por consulta	3 documentos y 10 fragmentos
Texto de salida	≤250 palabras; 0 terminaciones incompletas
Trazabilidad de salida	500/500 chunk_id, doc_id y texto verificados
Suite automatizada	60 pruebas aprobadas

Controles ejecutados

- `uv sync --python 3.12`.
- Verificador real de índice: alineación, campos, tipo y normas.
- Validador del paquete: estructura, esquema JSONL, generador, PDF y base.
- Cruce de resultados contra metadata: cada texto es un subfragmento del chunk declarado.
- Suite pytest completa.

El informe tiene siete páginas A4 y contiene las decisiones exigidas: chunking, encoder, índice FAISS y estado explícito del grafo.

7. Reproducibilidad, limitaciones y cierre

El manifiesto registra BAAI/bge-m3, dimensión 1.024, longitud 512, prefijos vacíos, versiones de construcción y hashes de las entradas. El índice plano no introduce aleatoriedad. Dos ejecuciones independientes produjeron archivos idénticos y el validador confirmó coincidencia byte a byte con resultados.jsonl.

Limitaciones conocidas

- Los pesos del encoder no se incluyen dentro de entrega/; deben estar disponibles en caché o descargarse desde el repositorio oficial del modelo.
- Los pesos se cargan desde la caché o el repositorio oficial y no se duplican dentro del paquete de entrega.
- Los PDFs escaneados sin OCR son la principal oportunidad futura de ampliar cobertura; reintroducirlos requiere extracción, chunking e indexación nuevos.
- El grafo y un segundo encoder no se implementaron; ambos son opcionales.

Estado final del paquete

Componente	Estado
resultados.jsonl	Presente; esquema, trazabilidad y fronteras validados.
generador.py	Presente; autónomo, no generativo y con escritura atómica.
informe_tecnico.pdf	Presente; siete páginas A4.
base_vectorial/encoder_bge-m3	Presente; índice, metadata y manifiesto verificados.

Conclusión

La entrega contiene los cuatro componentes obligatorios y satisface los controles estructurales, técnicos y de reproducción. La base real es cargable y está alineada; los resultados cumplen cardinalidad, límite y trazabilidad; el diseño evita modelos generativos; y la salida regenerada coincide byte a byte con el archivo final.

Fuentes: Especificación Técnica CODEFEST AD ASTRA 2026, Etapa 1, versión 1.0 (julio de 2026); manifest.json de la base; código y pruebas del repositorio.